

지식 주입형 언어 모델 기반 《승정원일기》 번역 모델 연구

1. 연구 배경

역사 기록물은 단순한 과거의 사실의 나열을 넘어, 당대 사회의 정치, 경제, 문화, 철학을 포괄하는 국가의 핵심적 학술 자산이다. 특히 대한민국의 대표적인 기록유산인 《승정원일기》는 유네스코(UNESCO) 세계기록유산으로 등재된 세계 최대 규모의 단일 역사 기록물로서 그 가치가 지대하다. 인조(1623 년)부터 순종(1907 년)에 이르기까지 조선 후기 왕실과 조정의 동향을 매일 기록한 이 문헌은 총 3,243 책, 약 2 억 4,250 만 자에 달하는 방대한 텍스트로 구성되어 있다.¹ 그러나 이토록 막대한 학술적, 문화적 가치에도 불구하고 《승정원일기》가 현대 사회에서 온전히 활용되는 데에는 극복하기 어려운 언어적 장벽이 존재한다. 바로 한문 원문을 현대 국어로 변환하는 국역 작업의 지연이다.

현재 국가 기관과 다수의 학계 전문가들이 참여하여 국역 사업을 진행하고 있으나, 전통적인 인력 기반 번역 프로세스의 한계로 인해 전체 번역 완료율은 37.4% 수준에 머무르고 있다. 전문적인 고전 한문 해독 능력을 갖춘 인력의 공급은 제한적인 반면, 해석해야 할 텍스트의 규모는 물리적 한계를 초과하기 때문에, 현재의 속도를 유지할 경우 완역은 2062 년에나 가능할 것으로 추산된다 . 이러한 병목 현상을 타개하고 지식 자산의 대중화 및 디지털화를 가속하기 위해 최근 자연어 처리와 인공지능에 기반한 기계 번역 기술이 대안으로 적극 검토되어 왔다.

초기 고전 한문 번역에는 범용 트랜스포머 모델이나 중국의 방대한 고문헌 코퍼스인 《사고전서(四庫全書)》 등을 학습한 언어 모델이 투입되었다. 대표적으로 SikuRoBERTa

아키텍처를 기반으로 한 AnchiLm 모델이나 기존 SikuBERT 와 대형 언어 모델(LLM)을 결합한 파이프라인이 시도되었다.³ 그러나 이들 모델은 일정 부분 문맥을 파악하는 데는 기여했으나, 전반적인 번역 품질을 나타내는 BLEU 지표가 0.37~0.54 의 낮은 수준에 정체되는 한계를 드러냈다. 더욱 심각한 문제는 원문에 등장하는 인칭대명사, 인명, 관직명, 지명 등 고유명사를 정확히 인식하고 번역하는 정확도가 8.3%에 불과했다는 점이다. 역사 번역에서 고유명사의 오역은 단순한 텍스트의 오류를 넘어 역사적 사실자체를 왜곡하는 결과를 초래하므로, 이는 인공지능 기반 번역 기술이 실무에 도입되는 것을 가로막는 가장 결정적인 장애물로 작용해 왔다.

본 연구 보고서는 기존 기계 번역 시스템이 지니고 있던 도메인 불일치와 환각 현상을 근본적으로 극복하기 위해 제안된 지식 주입형파이프라인의 핵심 로직과 기술적 타당성을 심층적으로 제시한다. 본 파이프라인은 기존 SikuBERT 와 Solar Pro 의 조합을 폐기하고, 오직 《조선왕조실록》 등 조선 시대 문헌만을 학습하여 도메인 특화 능력을 극대화한 SillokBERT 와, 다국어 처리 및 맥락 이해 능력이 뛰어난 구글의 경량 파운데이션 모델 Gemma 를 결합한 새로운 아키텍처를 채택하였다.⁵ 단순히 텍스트를 입력받아 블랙박스 형태로 출력하는 End-to-End 번역 방식을 탈피하여, 개체명 인식(NER), 고전 특화 지식 베이스(KB) 연동, 엔티티 링킹(Entity Linking)을 통한 동명이인 해소, 그리고 프롬프트 증강을 통한 최종 지식 주입 번역이라는 체계적인 6 단계 구조를 확립하였다.

2. 문제 정의

지식 주입형 파이프라인의 필요성을 명확히 이해하기 위해서는, 먼저 기존에 적용되었던 고전 한문 번역 모델들의 구조적 결함과 기술적 한계를 구체적으로 짚어볼 필요가 있다. 기존 모델들은 언어 능력과 사실적 지식을 하나의 모델 파라미터 내에 혼재하여 학습시키는 구조를 취했으며, 이는 고전문헌 번역에서 심각한 오류를 야기했다.

2.1 AnchiLm 및 SikuBERT 기반 모델의 도메인 불일치

고전 한문을 현대어로 번역하기 위한 선행 연구 중 하나인 AnchiLm 모델은 12 개 층의

인코더(Encoder)와 6 개 층의 디코더(Decoder)를 갖춘 트랜스포머 기반 구조를 사용하였다.³ 이 모델은 인코더 초기화에 SikuRoBERTa 를 사용하였으며, 병렬 코퍼스의 확장을 위해 바이트 페어 인코딩(BPE) 분할 과정을 무작위로 교란하는 bpe-drop 전략을 채택하였다.³ 이를 통해 EvaHan2023 번역 대회에서 BLEU 점수 21.75 를 기록하며 전통적인 베이스라인 모델을 상회하는 성과를 거두었다.³

그러나 AnchiLm 이나 SikuBERT 와 같은 모델들은 그 학습 코퍼스의 근간이 중국의 고문헌에 편중되어 있다는 태생적 한계를 지닌다. 중국의 《사고전서》와 조선의 《승정원일기》는 한자라는 표의문자를 공유하지만, 그 이면에 깔린 문법적 구조와 어휘의 용례, 특히 행정 체계와 관직명에서 극명한 차이를 보인다. 조선 시대 한문은 고유의 이두(吏讀)식 표현과 한국식 한자어, 그리고 독자적인 관직 및 지명 체계를 포함하고 있으므로, 중국 고문헌에 최적화된 모델은 조선 시대 텍스트의 맥락을 오독할 확률이 높다.⁷ 이는 모델이 보유한 사전 학습 가중치와 대상 텍스트 간의 심각한 도메인 불일치를 유발하며, 궁극적으로 0.37~0.54 라는 저조한 BLEU 점수를 기록하는 원인이 되었다.

2.2 암묵적 지식 의존에 따른 고유명사 환각 현상

기존 LLM 이나 신경망 기계 번역(NMT) 모델의 가장 치명적인 단점은 앞서 언급한 바와 같이 고유명사 번역 정확도가 8.3%에 불과하다는 점이다. 이러한 현상이 발생하는 근본적인 이유는 신경망 모델이 지식을 저장하고 추출하는 메커니즘 자체에 있다. 범용 번역 모델은 방대한 파라미터 네트워크 속에 수많은 정보가 암묵적 지식의 형태로 압축되어 있다. 원문 텍스트 내에 "命金鍾秀(김종수에게 명하여)"라는 구문이 주어졌을 때, 띄어쓰기가 없는 한문의 특성상 기존 모델은 '金(김)', '鍾(중)', '秀(수)'를 각각 개별적인 형태소로 분리하여 해석하려는 경향을 보인다. 혹은 '金鍾秀'를 하나의 인명으로 인식하더라도, 이 인물이 조선 영조와 정조 시대에 활동했던 특정 관료라는 역사적 팩트를 파라미터 내부에서 정확히 끄집어내어 현대 국어 표기로 매핑하는 것은 불가능에 가깝다. 그 결과, 모델은 확률적으로 가장 등장 빈도가 높은 다른 한자어의 조합으로 치환하거나, 전혀 엉뚱한 인물이나 관직명으로 번역하는 환각 현상을 필연적으로 발생시킨다. 이는 언어 구조를 디코딩하는 능력과 외부 세계의 팩트를 검증하는 능력을 철저히 분리하지 않고 하나의 모델에 전적으로 의존했기

때문에 발생하는 구조적 한계이다.⁸

3. 방법론


본 연구가 제안하는 지식 주입형 파이프라인은 이러한 기존 모델의 구조적 한계를 타파하기 위해, '구문론적 언어 변환'과 '팩트 복원'의 과정을 명확히 분리하여 각각 최적의 하위 모델에 할당하는 모듈화 철학을 따른다.⁸ 전체 파이프라인은 입력된 《승정원일기》 원문에서 개체명을 추출하고, 이를 지식 베이스와 대조하여 식별자를 특정된 뒤, 최종적으로 거대 언어 모델에 관련 지식을 증강하여 번역을 수행하는 단계로 구성된다.

3.1 지식 주입형 파이프라인 아키텍처

본 연구는 인조 및 정조 시기 『승정원일기』의 고도화된 기계 번역을 실현하기 위해 도메인 특화 지식베이스(KB)와 개체명 인식(NER) 및 엔티티 링킹 기술을 유기적으로 결합한 지식 주입형 번역 파이프라인을 제안한다.

우선 『조선왕조실록』을 기반으로 구축된 SillokBERT 모델에 『승정원일기』 원문 데이터를 활용한 마스크 언어 모델링(MLM)을 수행함으로써, 해당 사료 고유의 문법 체계와 문체를 모델 가중치에 사전 학습한다. 이어지는 단계에서는 학습된 가중치를 전이하여 개체명 인식(NER) 전용 출력층을 미세 조정함으로써 원문 내 인물명 추출의 정밀도를 확보하며, 이를 고전 특화 인물 정보 사전과 대조하는 다단계 엔티티 링킹 프로세스—성명 기반 후보군 검색, 활동 시기 검증—을 통해 개체의 고유 식별자를 확정한다. 확정된 인물 정보는 번역관 페르소나와 결합된 지식 주입형 프롬프트로 조립되어 Gemini-2.5-flash 모델의 최종 번역 생성에 활용된다.

최종적으로 식별된 지식베이스 정보와 원문을 결합한 프롬프트 증강 전략을 활용하여 대규모 언어 모델(LLM)이 역사적 맥락과 고유 명사의 정확성이 엄밀하게 담보된 고품질의 번역본을 도출하도록 구조화하였다.



3.2 승정원일기 특화 언어 모델 구축을 위한 도메인 적응

본 연구는 범용 고전 한문 모델의 언어 표현 능력을 《승정원일기》의 문체적·어휘적 특성으로 심화시키기 위해 계속 사전학습(Continued Pre-training, CPT) 기반의 도메인 적응을 수행하였다. 기반 모델로는 HuggingFace Hub에 공개된 SillokBert-Scratch를 채택하였다. 해당 모델은 BERT 기반의 다국어 인코더 아키텍처를 따르며, 《조선왕조실록》 원문으로 사전학습되어 고전 한문에 대한 기초적인 문맥 표현 능력을 보유하고 있다. 그러나 《승정원일기》는 실록과 달리 이두(吏讀) 표현·구어적 보고 문체·비서실 행정 고유 어휘가 혼재하는 독자적인 언어 층위를 형성하고 있어, 실록 기반 모델을 직접 적용하기에는 명확한 한계가 존재한다. 이에 모델의 기존 지식을 보존하면서 승정원일기의 문맥적 패턴을 점진적으로 주입하는 CPT 방식을 채택하였다.

학습 방법론으로는 마스크 언어 모델링(Masked Language Modeling, MLM)을 적용하였다. 이는 입력 시퀀스 내 전체 토큰의 15%를 무작위로 마스킹한 뒤 원래 토큰을 복원하도록 모델을 학습시키는 비지도 방식으로, 별도의 레이블 데이터 없이 원문 코퍼스만으로 도메인 특화 문맥 표현을 획득할 수 있다는 점에서 광범위한 미번역 원문이 존재하는 《승정원일기》의 데이터 환경에 적합하다. 학습 대상 코퍼스는 인조 연간 《승정원일기》 합산 원문이며, 토큰나이징 과정에서 물리적 결락을 나타내는 손상 기호(□, ○ 등)를 제거하지 않고 학습 데이터로 수용하였다. 이는 결락이 존재하는 불완전한 문장 환경에서도 앞뒤 문맥을 통해 누락된 개체명이나 어구를 유추할 수 있는 역사적 추론 능력을 모델에 내재화하기 위한 의도적 설계 결정이다.

학습은 Google Colab A100 GPU 환경에서 수행하였으며, 메모리 부족 현상에 대응하여 per_device_train_batch_size=8과 그래디언트 누적 16단계를 결합하여 실효 배치 크기 128을 확보하였다. Gradient Checkpointing과 fp16 혼합 정밀도 학습을 병행하여 VRAM 사용량과 연산 효율을 동시에 관리하였으며, 런타임 단절에 대비한 체크포인트 자동 재개 로직을 구현하여 장시간 학습의 안정성을 보장하였다. 전체 학습 구성은 표 1에 정리하였다.

<표1>

항목	설정
기반 모델	SillokBert-Scratch (BERT-base-multilingual-cased)
학습 대상 코퍼스	인조 연간 《승정원일기》 원문
학습 방법론	MLM 기반 Continued Pre-training
마스킹 비율	15% (mlm_probability=0.15)
최적화 알고리즘	AdamW (lr=5e-5, Cosine Decay, Warmup Ratio=0.05)
실효 배치 크기	128 (per_device=8 × Gradient Accumulation=16)
연산 정밀도	fp16 + Gradient Checkpointing
시퀀스 최대 길이	512 tokens
연산 환경	Google Colab A100 GPU (VRAM 40GB)

이상의 도메인 적응 과정을 거쳐 구축된 모델은 《승정원일기》 특유의 어휘 분포와 문체에 대한 심화된 문맥 표현 능력을 획득하였으며, 이후 3.3절에서 서술하는 개체명 인식(NER) 단계의 인코더로 활용된다.

3.3 개체명 인식 모델 구축을 위한 파인튜닝

3.2절에서 구축한 도메인 적응 모델에 토큰 분류 헤드를 부착하고, 수동 레이블 없이 의사 레이블(Pseudo-label) 기반의 자동 학습 데이터를 생성하여 개체명 인식 모델을 파인튜닝하였다. 인식 대상 개체는 인물(PER), 관직(POS), 지명(LOC), 날짜(DAT)의 4종이며, BIO 태깅 체계를 적용하여 O를 포함한 총 9개의 태그로 구성하였다. 학습에 앞서 원문 문장 중 400자 이상의 장문은 구결 부호(。 , 、) 및 공백을 기준으로 분절하여 BERT의 최대 입력 길이 제약에 대응하였다.

학습 데이터 구축에는 HuggingFace Hub에 공개된 SillokBert-NER을 레이블러 모델로 활용하는 Silver Label 자동 생성 방식을 채택하였다. 레이블러가 원문 문장에 NER 추론을 수행한 뒤, 개체 토큰 전체의 예측 신뢰도가 임계값(CONF_THRESHOLD=0.90) 이상인 문장만을 학습 데이터로 채택하는 신뢰도 기반 필터링을 적용하였다. 이는 고품질 병렬 코퍼스가 극히 제한적인 환경에서 수동 레이블링 비용을 최소화하면서도 노이즈를 통제하기 위한 설계 결정이다. 서브워드 토크나이징 과정에서는 word_ids()를 활용한 정렬(subword alignment)을 수행하여 각 단어의 첫 번째 서브워드에만 실제 레이블을 부여하고, 나머지 서브워드 위치는 -100으로 처리하여 손실 계산에서 제외하였다. 필터링을 통과한 데이터는 9:1 비율로 학습·검증 세트로 분할하였다.

모델 초기화 시에는 final_ner_model 내 체크포인트 존재 여부를 자동으로 탐지하여, 체크포인트가 있을 경우 해당 시점에서 학습을 재개하고, 없을 경우 3.2절의 MLM 결과물에 NER 헤드를 신규 부착하는 분기 로직을 구현하였다. MLM 헤드와 NER 헤드 간의 출력 차원 불일치를 허용하기 위해 ignore_mismatched_sizes=True 옵션을 명시적으로 지정하였다. 모델 평가에는 seqeval 라이브러리를 적용하여 시퀀스 레벨의 Precision, Recall, F1을 산출하였으며, F1을 기준으로 최적 모델을 자동 선택하도록 설정하였다. 전체 학습 구성은 표 2에 정리하였다.

<표2>

항목	설정
기본 모델	3.2절 CPT 결과물 (final_model) + TokenClassification Head
레이블 체계	BIO 태깅, 9개 태그 (O, B/I-PER, B/I-POS, B/I-LOC, B/I-DAT)
학습 데이터 구축	SillokBert-NER Silver Label 자동 생성

항목	설정
신뢰도 임계값	0.90
데이터 분할 비율	학습 90% / 검증 10% (seed=42)
최적화 알고리즘	AdamW (lr=2e-5, Weight Decay=0.01, Warmup Ratio=0.1)
학습 에폭	3
배치 크기	32
연산 정밀도	fp16
평가 지표	seqeval F1

3.4 고전 특화 지식 베이스의 구축

NER 단계에서 식별된 개체를 실제 역사 인물·관직·지명으로 연결하고, 이를 최종 번역 모델에 효율적으로 주입하기 위해 고전 특화 지식 베이스(Knowledge Base, 이하 KB)를 구축하였다. 전체 원천 사전(person_master.json)을 모체로 하되, 본 연구의 분석 대상인 인조 연간에 실제 등장하는 인물만을 추출하여 실시간 번역 공정의 병목을 방지하고 LLM 프롬프트 주입 효율을 극대화하는 2종의 경량 JSON 파일로 구성하였다.

첫 번째 파일은 경량 조회 사전(id_lookup_injo.json)으로, 인조 연간 활동 인물 2,690명의 핵심 메타데이터를 수록한 원천 레코드이다. 각 인물은 고유 식별자(M_XXXXXXX 형식)를 키로 하며, 한글_명·한자_명·본관_표준_활동_시작_활동_종료_관직_리스트의 6개 필드로 구성된다. 활동_시작과 활동_종료는 생몰년이 불분명한 인물의 경우 최초·최후 관직 발령 연도를 기준으로 추정하여 보완하였으며, 관직_리스트는 인물당 평균 9.6개(최대 85개)의 관직을 이력 순으로 수록하여 모델이 특정 시점의 문맥 속에서 해당 인물의 직위 변화를 추적할 수 있도록 하였다.

두 번째 파일은 멀티 키 탐색을 위한 역색인 인덱스(inverted_index_injo.json)이다. 고문헌에서는 성씨가 탈락한 채 이름만으로 인물을 지칭하거나(예: '강선(姜璿)'을 '璿' 혹은 '선'으로만 표기), 이체자(異體字)가 혼용되는 경우가 빈번하다. 이에 한자 전체명(4,225개)·한자 단독 이름(544개)·한글 전체명(4,112개)·한글 단독 이름(223개)·이체자 및 기타(299개)를 모두 독립적인 키로 등록하여 총 9,403개의 검색 키를 구성하였으며, 각 키는 해당 표기로 식별

가능한 인물 ID의 후보 리스트를 값으로 가진다. 이 구조는 해시맵 기반의 $O(1)$ 복잡도로 후보군을 즉시 추출할 수 있게 하여 실시간 처리 효율을 확보한다.

구축된 KB를 기반으로 지능형 개체 링크 엔진을 운용하였다. 역색인 검색으로 1차 후보군을 추출한 뒤, 동명이인이 발생한 경우(813개 키, 최대 21인 후보)에는 일기 작성 시점과 인물의 활동_시작·활동_종료를 대조하는 시간 필터를 1차 적용한다. 이때 사후 추증(追贈)이나 회고적 서술의 누락을 방지하기 위해 활동_종료 기준의 상한 필터링은 의도적으로 완화하였다. 이후 원문 내 관직명과 KB의 관직_리스트를 교차 검증하여 중의성을 추가 해소하며, 최종적으로 중의성이 잔존하는 모호한 케이스에 대해서는 후보군 전체를 LLM에 전달하여 문맥 기반의 최종 식별을 유도하는 구조를 취하였다. 전체 KB 구성은 표 3에 정리하였다.

<표3>

파일명	항목 수	역할	주요 필드
id_lookup_injo.json	2,690명	인물 메타데이터 원천 레코드	한글_명, 한자_명, 본관_표준, 활동_시작, 활동_종료, 관직_리스트
inverted_index_injo.json	9,403 키	멀티 키 고속 역색인 탐색	한자·한글 전체명, 단독 이름, 이체자 등 표기 변형 전체

3.5 KB 링크 효과 검증 실험 결과


(1) 실험 설계

KB 연계 여부가 번역 품질에 미치는 영향을 정량·정성적으로 평가하기 위해 AB 테스트를 설계하였다. 비교 조건은 두 가지로, KB 있음(with-KB) 조건은 NER 결과를 KB와 연결하여 인물 맥락 정보를 프롬프트에 포함한 번역이며, KB 없음(without-KB) 조건은 동일한 원문을 맥락 정보 없이 번역한 것이다. 평가 대상 문장은 NER 캐시(ner_cache.json)에서 KB 매칭이 1건 이상 성공한 문장을 추출하고, random.seed(42)로 최대 100문장을 샘플링하여 sample_for_comparison.json에 저장하였다.

(2) KB 엔티티 링크 방법

KB 검색 함수 `search_kb(surface)`는 3단계 fallback 구조로 구현되었다. 1차 검색은 표층형 전체 문자열을 역인덱스(`inverted_index_injo.json`)에서 직접 조회하며, 2차 검색은 각 글자별 후보 집합의 교집합을 산출하고, 3차 검색은 개별 글자 합집합으로 후보 범위를 확장한다. 최종 필터링 단계에서는 KB 항목의 한자명에 표층형의 모든 글자가 포함되는 후보만을 통과시켜 오매칭을 억제하였다.

매칭 대상은 NER 결과 중 PER·POS 태그이며, 한자가 포함된 표층형에 한정하였다. 중복 표층형은 seen 집합으로 제거하여 동일 인물이 반복 등장하더라도 맥락 정보가 중복 삽입되지 않도록 하였다. 매칭 결과는 `format_kb_context()` 함수를 통해 자연어 프롬프트 문자열로 변환되며, 후보가 1인인 경우에는 확정 정보를, 복수인 경우에는 "문맥에 맞는 인물을 선택하여 번역에 반영하라"는 선택지 형식으로 모델에 전달된다. 관직 목록은 단일 후보 시 최대 5개, 복수 후보 시 최대 3개로 제한하여 프롬프트 길이를 통제하였다.



(3) 번역 API 구성

번역에는 Gemini 2.5 Flash 모델을 사용하였다. 이 모델은 동급 Pro 대비 RPM이 약 20배 높고 비용이 대폭 낮아 대규모 비교 실험에 적합하다. 시스템 프롬프트는 '조선시대 승정원일기 전문 번역관' 페르소나로 설정하였으며, ① 고전적 현대 한국어 문체 유지, ② 인물·관직 맥락 반영, ③ 인명·관직명 한글+한자 병기, ④ 번역문만 출력(부가 설명 없음)의 네 가지 규칙을 명시하였다. `temperature=0.2`로 설정하여 번역의 일관성을 높였다.

API 호출 효율화를 위해, 기존에 청크 N개마다 API를 N회 호출하던 방식을 청크를

공백으로 연결하여 1회만 호출하는 방식으로 개선하였다. 재시도 로직은 최대 6회 지수 백오프(exponential backoff)를 적용하였으며, 오류 유형별로 429/quota는 최대 120초 대기 후 재시도, 500/503은 10초 대기, 404는 즉시 중단으로 처리하였다.

(4) 실험 결과

100문장 전체에서 API 성공률 100%를 달성하였으며, KB 있음/없음 번역 간 차이는 전 문장(100/100)에서 확인되었다. 문장당 평균 KB 매칭 인물 수는 2.0명이었으며, 평균 번역 길이는 KB 있음 994자, KB 없음 985자로 유사하였다. 한자 병기 횟수는 KB 있음 조건에서 4,417회, KB 없음 조건에서 4,167회로 KB 연계 시 약 6% 증가하였다.

정성 분석에서 KB 링크의 효과가 두드러진 유형은 세 가지로 분류되었다.

첫째, 인명 경계 오류 방지이다. 원문 崔有後陪進에서 KB 없음 조건은 '최유후(崔有後)'로 인명 경계를 잘못 획정하였으나, KB가 '최유(崔有)'를 독립 인물로 명시함으로써 '최유(崔有)가 뒤따라 올렸다'로 정확하게 분리되었다. 둘째, 문맥 해석 분기이다. 원문 前府院君李貴邊情事에서 KB 없음 조건은 '邊'을 '변방'으로 해석하였으나, KB 있음 조건은 '邊'을 별도 인명 엔티티로 태깅하여 번역 해석 자체가 달라졌다. 셋째, 인물 풀네임 복원이다. 원문 使馨長言于梧將에서 KB 없음 조건은 '형장(馨長)'으로 불완전하게 처리하였으나, KB 있음 조건은 '이형장(李馨長)'으로 성씨를 포함한 완전한 인명을 제공하였다.

한계 및 문제점은 다음과 같다. 두 가지 한계가 관찰되었다. 첫째, NER 오탐률이 높다. KB 미등록 엔티티 468개 중 111개(24%)가 인명이 아닌 표현에 PER 태그가 부여된 오탐으로 분석되었다. 오탐 사례로는 義禁府啓曰(관청명+동사구), 爲禮曹正郎(관직 임명 표현), 後弊無窮(서술구) 등이 있었다. 이를 개선하기 위해 NER confidence threshold를 현행 0.90에서 0.95로 상향하거나, 4자 이상 PER 태그를 후처리 필터링하는 방안을 검토할 필요가 있다. 둘째, 전반적인 번역 품질 향상 효과는 제한적이다. Gemini 2.5 Flash가 한문 번역 자체를 높은 수준으로 수행하므로, KB 연계의 차별적 기여는 인명 경계 모호 사례 및 동음이의 해석이 분기되는 사례에 집중되는 경향이 있었다.

참고 자료

1. 국사편찬위원회, 4 월 7, 2026 에 액세스, <https://www.history.go.kr/>
2. 승정원일기, 4 월 7, 2026 에 액세스,

<https://sjw.history.go.kr/main.do;jsessionid=494F3C6D343003058D6E110CEE20C179>

3. AnchiLm: An Effective Classical-to-Modern Chinese Translation Model Leveraging bpe-drop and SikuRoBERTa - ACL Anthology, 4 월 7, 2026 에 액세스, <https://aclanthology.org/2023.alt-1.8.pdf>
4. AnchiLm: An Effective Classical-to-Modern Chinese Translation Model Leveraging bpe-drop and SikuRoBERTa - ACL Anthology, 4 월 7, 2026 에 액세스, <https://aclanthology.org/2023.alt-1.8/>
5. Multilingual innovation in LLMs: How open models help unlock global communication, 4 월 7, 2026 에 액세스, <https://developers.googleblog.com/unlock-global-communication-gemma-projects/>
6. [2601.09012] TranslateGemma Technical Report - arXiv, 4 월 7, 2026 에 액세스, <https://arxiv.org/abs/2601.09012>
7. ddokbaro/SillokBert-NER · Hugging Face, 4 월 7, 2026 에 액세스, <https://huggingface.co/ddokbaro/SillokBert-NER>
8. Knowledge-Injected Transformer (KIT): A Modular Encoder–Decoder Architecture for Efficient Knowledge Integration and Reliable Question Answering - MDPI, 4 월 7, 2026 에 액세스, <https://www.mdpi.com/2076-3417/16/3/1601>